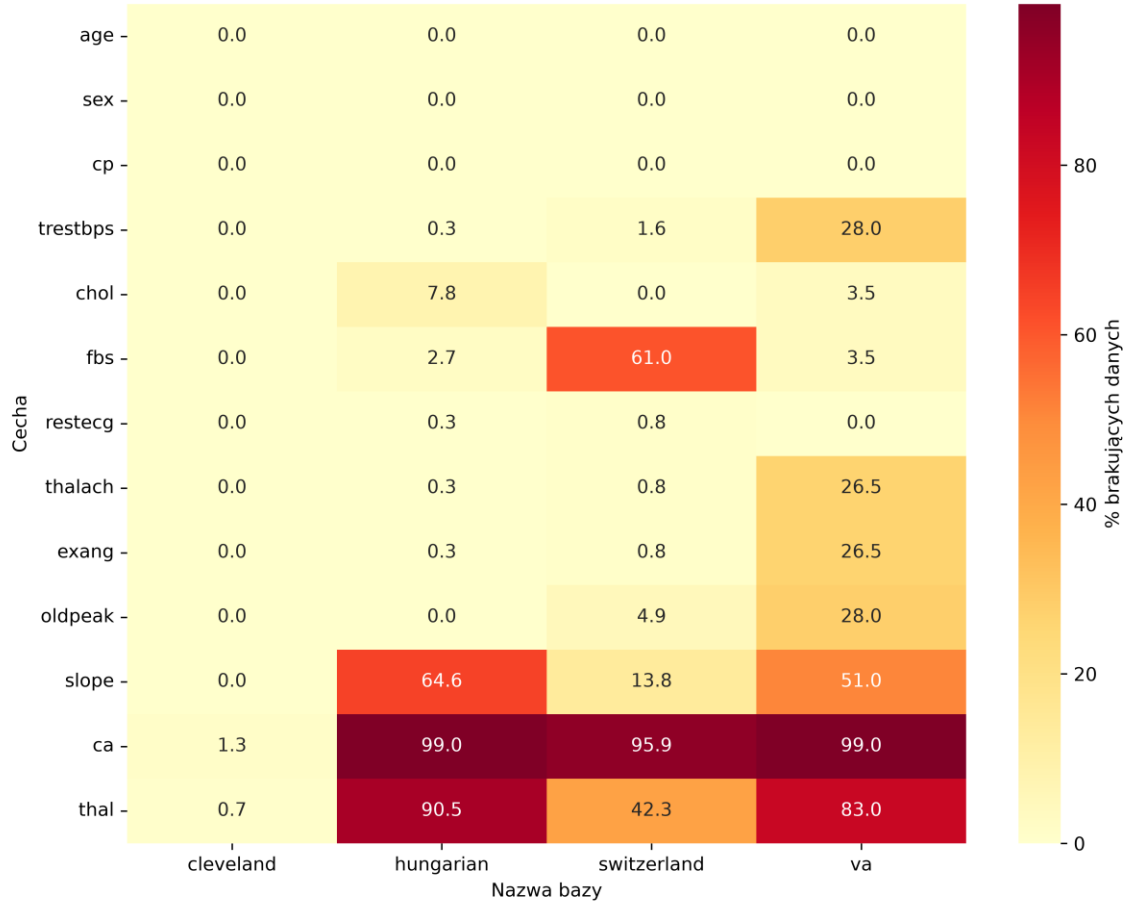
Raport 1 Sieci Neuronowe

Michał Frysiek

Zbiór heart+disease zawiera 4 bazy danych. Z powodu drastycznych braków danych, do analizy wykorzystano bazę *Cleveland*.



Wykres 1. Mapa cieplna przedstawiająca odsetek brakujących wartości w poszczególnych bazach zbioru UCI Heart Disease

Tabela 1. Statystyki ilościowe baz danych zbioru UCI Heart Disease

Baza danych	Liczba wierszy	Suma braków
processed.cleveland.data	303	6
processed.hungarian.data	294	782
processed.switzerland.data	123	273
processed.va.data	200	698

Baza składa się z 14 cech, gdzie ostatnia jest etykietą.

Tabela 2. Wykaz cech zbioru Cleveland

Indeks	Nazwa cechy	Nazwa polska	Typ cechy	Wartości
1	age	Wiek	Liczbowa	29 – 77
2	sex	Płeć	Kategoryczna	0, 1
3	cp	Typ bólu klatki piersiowej	Kategoryczna	1, 2, 3, 4
4	trestbps	Spoczynkowe ciśnienie krwi	Liczbowa	mm Hg (94 – 200)
5	chol	Cholesterol w surowicy	Liczbowa	mg/dl (126 – 564)
6	fbs	Cukier we krwi na czczo	Kategoryczna	0, 1
7	restecg	Spoczynkowe EKG	Kategoryczna	0, 1, 2
8	thalach	Maksymalne tętno	Liczbowa	bpm (71 – 202)
9	exang	Dusznica powysiłkowa	Kategoryczna	0, 1
10	oldpeak	Obniżenie odcinka ST	Liczbowa	mm / mV (0.0 – 6.2)
11	slope	Nachylenie odcinka ST	Kategoryczna	1, 2, 3
12	ca	Liczba głównych naczyń	Kategoryczna	0, 1, 2, 3
13	thal	Scyntygrafia talowa	Kategoryczna	3, 6, 7
14	num	Diagnoza	Etykieta (klasa)	0, 1, 2, 3, 4

Etykiety:

0 – zdrowy pacjent (zwężenie średnicy naczynia < 50%)

1, 2, 3, 4 – pacjent chory (zwężenie średnicy naczynia > 50% w 1, 2, 3 lub 4 naczyniach)

Ściśle patrząc, zbiór nie jest zbalansowany – zdecydowaną przewagę ma klasa 0.

Tabela 3. Liczebność i udział procentowy klas oryginalnych w zbiorze

Klasa	Próbki	Procent
0	164	54.13%
1	55	18.15%
2	36	11.88%
3	35	11.55%
4	13	4.29%

Z kolei gdy połączyć etykiety 1, 2, 3, 4 w jedną – czyli osobę chorą (klasa 1) - zbiór jest w przybliżeniu zbalansowany.

Tabela 4. Liczebność i udział procentowy klas binarnych w zbiorze

Klasa	Próbki	Procent
0	164	54.13%
1	139	45.87%

Tabela 5. Średnie i odchylenia standardowe cech liczbowych

Funkcja	age	trestbps	chol	thalach	oldpeak
mean	54.44	131.69	246.69	149.61	1.04
std	9.04	17.6	51.78	22.88	1.16

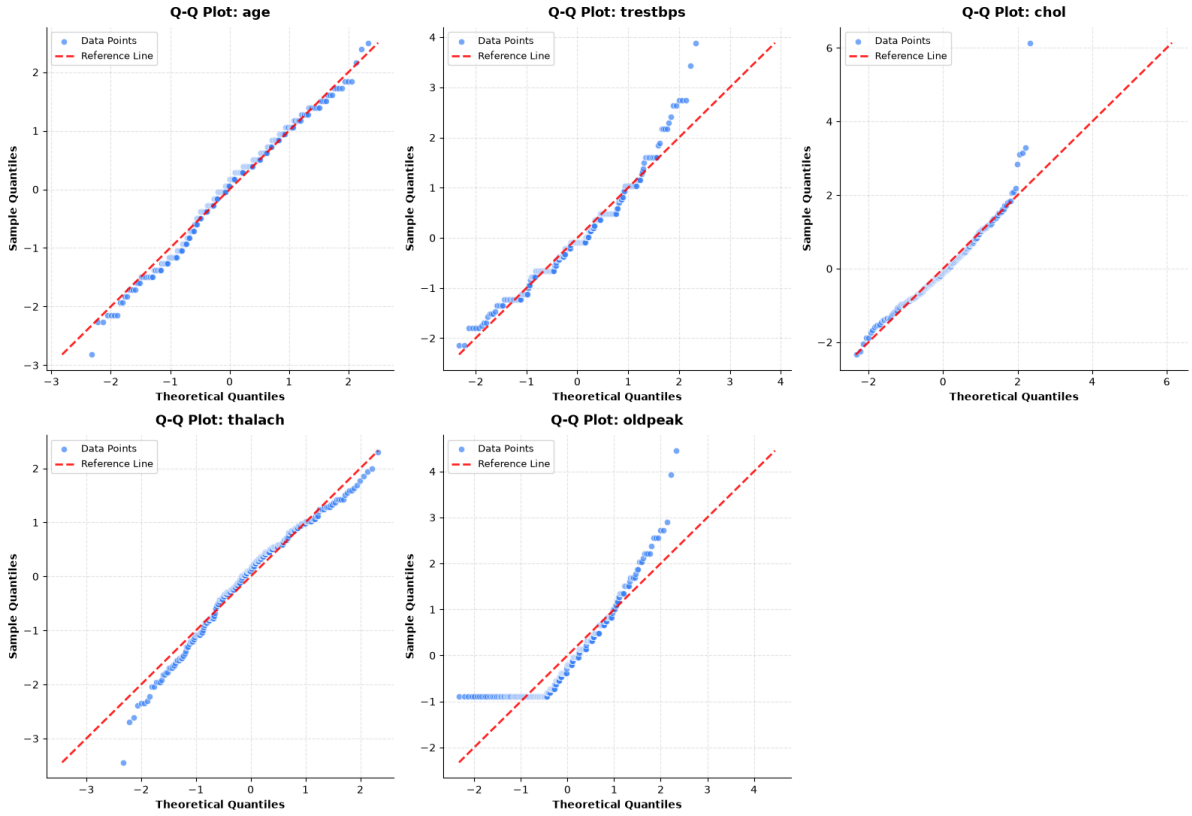
Aby sprawdzić czy rozkład danych jest dokładnie normalny, można zastosować metodę Shapiro Wilka.

Tabela 6. Analiza charakterystyki rozkładu cech liczbowych metodą Shapiro Wilka

Indeks	Cecha	Wynik testu Shapiro Wilka	Wartość p	Czy rozkład normalny? (p > 0.05)
0	age	0.986	6.0686e-03	False
1	trestbps	0.967	1.8021e-06	False
2	chol	0.947	5.9115e-09	False
3	thalach	0.976	6.9965e-05	False
4	oldpeak	0.844	8.1834e-17	False

Żadna cecha nie ma dokładnie rozkładu normalnego.

Żeby sprawdzić czy rozkład jest w przybliżeniu normalny, można wykorzystać wykres kwantyl-kwantyl dla każdej z cech, co przedstawiono na Wykresie 2.



Wykres 2. Wykresy kwantyl-kwantyl (Q-Q) dla cech liczbowych zbioru Cleveland

Na podstawie analizy wykresów można stwierdzić, że jedynie cechy *age* i *thalach* wykazują rozkłady zbliżone do rozkładu normalnego. Reszta wykazuje się pewnymi asymetriami.

Aby zbadać rozkład cech kategorycznych, wykorzystuje się test chi-kwadrat.

Tabela 7. Analiza charakterystyki rozkładu cech kategorycznych testem chi-kwadrat

Cecha	Liczba unikalnych klas	Wynik Chi^2	Wartość p	Czy rozkład równomierny? (p > 0.05)
sex	2	39.21	3.8035e-10	False
cp	4	108.37	2.4654e-23	False
fbs	2	149.73	1.9833e-34	False
restecg	3	139.78	4.4329e-31	False
exang	2	36.39	1.6185e-09	False
slope	3	95.07	2.2697e-21	False
ca	4	196.59	2.3065e-42	False
thal	3	113.31	2.4847e-25	False

Wyniki pokazują, że żadna z cech kategorycznych nie ma rozkładu równomiernego. Obrazuje to również poniższa tabela.

Tabela 8. Podsumowanie rozkładu cech kategorycznych

Cecha	Klasa	Liczba	Procent
sex	0.0	97	32.01%
sex	1.0	206	67.99%
cp	1.0	23	7.59%
cp	2.0	50	16.50%
cp	3.0	86	28.38%
cp	4.0	144	47.52%
fbs	0.0	258	85.15%
fbs	1.0	45	14.85%
restecg	0.0	151	49.83%
restecg	1.0	4	1.32%
restecg	2.0	148	48.84%
exang	0.0	204	67.33%
exang	1.0	99	32.67%
slope	1.0	142	46.86%
slope	2.0	140	46.20%
slope	3.0	21	6.93%
ca	0.0	176	58.86%
ca	1.0	65	21.74%
ca	2.0	38	12.71%
ca	3.0	20	6.69%
thal	3.0	166	55.15%
thal	6.0	18	5.98%
thal	7.0	117	38.87%

W zbiorze *cleveland* występują wartości brakujące, jednak łącznie stanowią ~1.98% wszystkich wierszy w bazie.

Tabela 9. Podsumowanie braków w danych dla zbioru Cleveland

Cecha	Liczba braków	Procent [%]
ca	4	1.32
thal	2	0.66

Cechy *ca* i *thal* są kategoryczne, a więc zamiast średniej można użyć imputacji modą. Alternatywnie można usunąć 6 wierszy z brakami, co nie spowoduje utraty reprezentatywności danych.

Do podziału danych wykorzystano 10-krotnie powtórzoną stratyfikowaną 5-krotną walidację krzyżową. W zbiorze treningowym cechy liczbowe ustandaryzowano, a dla cech kategorycznych niebinarnych skorzystano z One-Hot Encoding.

Tabela 10. Wybrana część przetworzonych danych

Indeks	age	sex	trestbps	chol	fbs	thalach	exang	oldpeak	cp_2.0	cp_3.0	cp_4.0	restecg_1.0	restecg_2.0	slope_2.0	slope_3.0	thal_6.0	thal_7.0	ca_1.0	ca_2.0	ca_3.0
180	-0.729484	1.0	-0.395691	0.4581394	0.0	0.7083712	0.0	-0.445444	0.0	0.0	1.0	0.0	1.0	1.0	0.0	0.0	1.0	0.0	0.0	0.0
208	0.0501664	1.0	-0.054513	0.2305976	0.0	0.2224953	0.0	-0.891627	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
167	-0.061212	0.0	0.0592127	0.7236048	1.0	0.3991775	1.0	-0.891627	1.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0
105	-0.061212	1.0	-1.305501	1.1218029	0.0	0.2666659	0.0	-0.891627	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0
297	0.2729239	0.0	0.5141174	-0.167600	0.0	-1.190961	1.0	-0.713154	0.0	0.0	1.0	0.0	0.0	1.0	0.0	0.0	1.0	0.0	0.0	0.0

Do ustalenia baseline'u wykorzystano algorytm k-najbliższych sąsiadów. Uśrednione wyniki prezentują się następująco:

KNeighborsClassifier:

Accuracy: 0.8010

Balanced Accuracy: 0.7959

Precision: 0.8180

Recall: 0.7332

F1-Score: 0.7706
