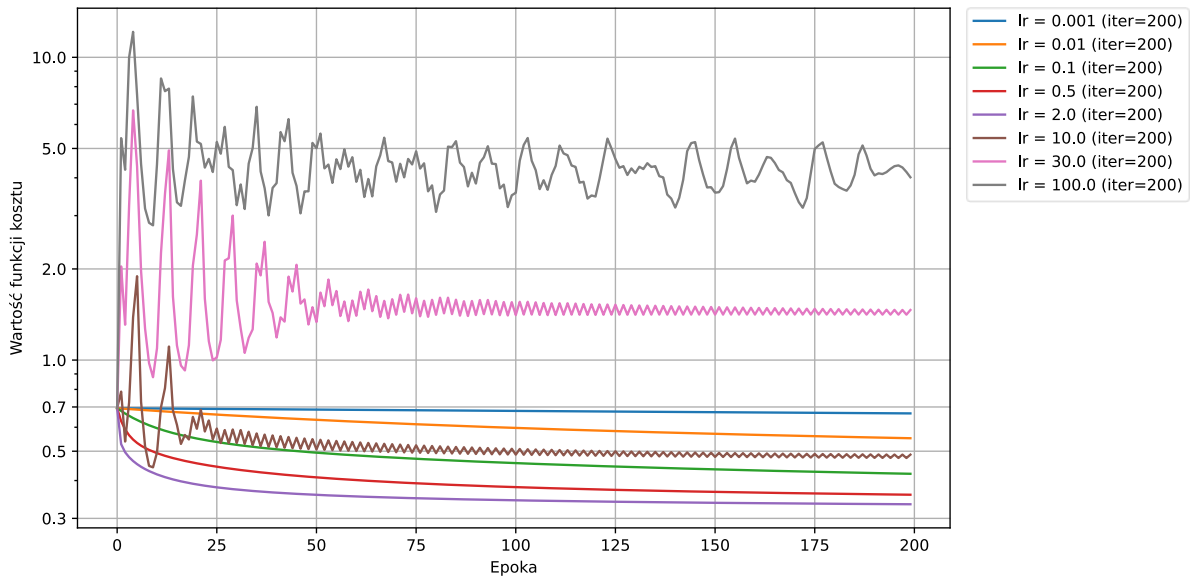
Raport 2 Sieci Neuronowe

Michał Frysiek

Ze względu na niewielki rozmiar zbioru danych (~300) zrezygnowano z podziału train/val/test na rzecz podziału train/val (80/20).

Do badania wpływu hiperparametru *learning rate* zastosowano inicjalizację wag wartościami zerowymi ($W = 0, b = 0$). Zerowa inicjalizacja zapewnia brak początkowego obciążenia modelu.

Aby dokładniej zobrazować przebieg zbieżności, wybrano na początek wycinek składający się z 200 epok.

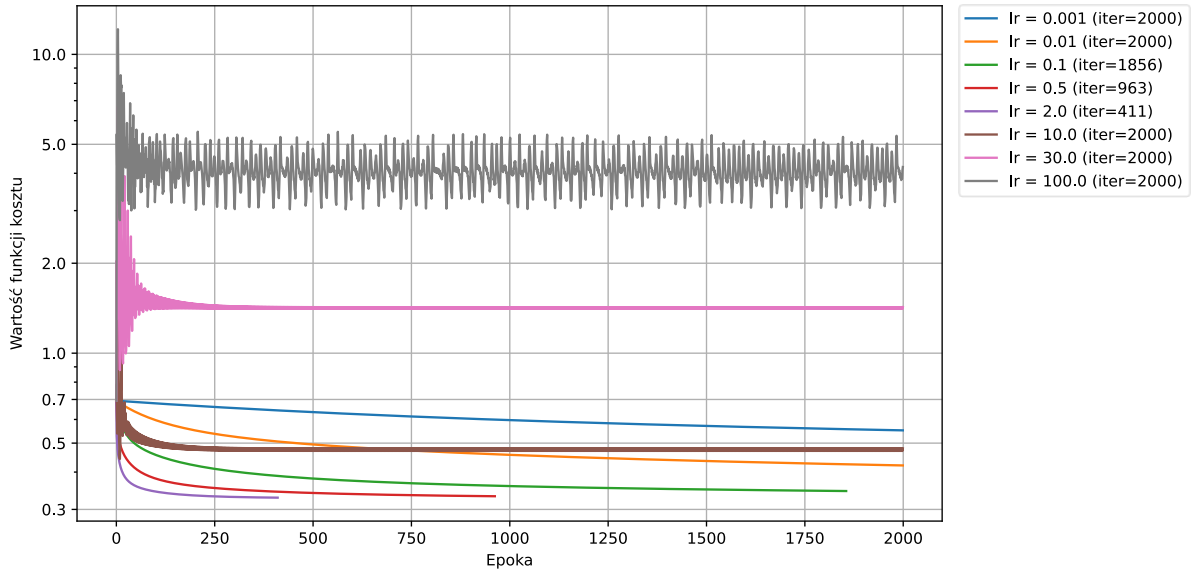


Wykres 1. Wpływ współczynnika learning rate na zbieżność – 200 epok

Widoczne są zjawiska:

1. Zbyt mały krok (wartości 0.001 i 0.01) – praktycznie płaskie linie, bardzo powolna zbieżność
2. Optymalna zbieżność (wartości 0.1; 0.5; 2.0) – gładkie, malejące bez odchyleń krzywe.
3. Prawdopodobna granica stabilności (wartość 10.0) – początkowo gwałtowna, później regularne oscylacje wokół minimum globalnego.
4. Zbyt duży krok (wartości 30.0, 100.0) – chaotyczne skoki i skakanie nad minimum globalnym, utknięcie na poziomie wyższego błędu.

Poniższy wykres przedstawia szerszy zakres uczenia oraz momenty zbieżności dla pewnych parametrów. Najszybciej zbieżność osiąga model z parametrem learning rate = 2.0.



Wykres 2. Wpływ współczynnika learning rate na zbieżność – 2000 epok

Tabela 1. prezentuje wyniki metryk dla przebiegu 2000 epok. Liczba epok = 2000 w tabeli oznacza w tym wypadku, że dla danej wartości parametru *learning rate* model nadal nie osiągnął zbieżności.

Tabela 1. Metryki klasyfikacji dla różnych wartości hiperparametru learning rate

Learning Rate	Liczba epok do zbieżności	F1-Score	Precision	Recall	Accuracy	Final Loss
0.001	2000	0.839	0.765	0.929	0.836	0.552
0.01	2000	0.9	0.844	0.964	0.902	0.421
0.1	1856	0.877	0.862	0.893	0.885	0.346
0.5	963	0.862	0.833	0.893	0.869	0.332
2.0	411	0.862	0.833	0.893	0.869	0.328
10.0	2000	0.906	0.96	0.857	0.918	0.48
30.0	2000	0.816	0.952	0.714	0.852	1.426
100.0	2000	0.792	0.95	0.679	0.836	4.199

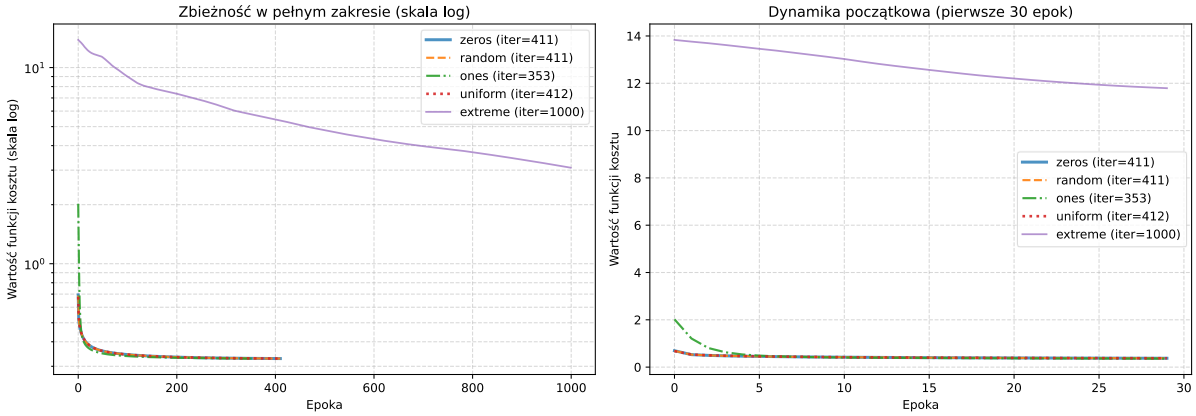
Model dla $lr = 0.5$ i $lr = 2.0$ osiągnął identyczne metryki jakości na zbiorze testowym i niemal identyczny $Final\ Loss$. Oznacza to, że oba procesy optymalizacji dotarły w to samo minimum funkcji straty, gdzie jedyną różnicą jest koszt obliczeniowy (dla $lr = 0.5$ jest to 963 epok, a dla $lr = 2.0$ tylko 411 epok).

Model dla $lr = 0.1$ osiągnął podobne wyniki, natomiast proces zbieżności trwał znacznie dłużej - 1856 epok.

Przy $lr = 10.0$ model osiągnął najwyższą wartość F1 oraz Accuracy. Jak jednak widać na wykresie nie osiągnął zbieżności – utknął na wartości $Final\ Loss = 0.48$ z powodu oscylacji wokół minimum.

Dla $lr \geq 30.0$ wartość funkcji straty nie spada do akceptowalnych poziomów. Widoczny jest również zauważalny spadek metryki $Recall = 0.679$ spowodowany zbyt agresywnym krokiem.

W związku z poprzednimi wynikami, do badania wpływu inicjalizacji wag na zbieżność w eksperymentach wykorzystano $lr = 2.0$.



Wykres 3. Wpływ inicjalizacji wag na zbieżność

Testowane wagi:

1. ***zeros*** – wszystkie wagi oraz bias przyjmują wartość 0.
2. ***random*** – wagi losowane z rozkładu normalnego o zerowej średniej i bardzo małym odchyleniu standardowym, $b = 0.0$.
3. ***uniform*** – W losowane z $U(-\frac{1}{\sqrt{d}}, \frac{1}{\sqrt{d}})$, gdzie d to liczba wejść, $b = 0.0$.
4. ***ones*** – każda waga oraz bias ustawione są na sztywno na 1.0.
5. ***extreme*** – W losowane z przedziału $(-50.0, 50.0), b = 0.0$

Tabela 2. Wyniki metryk dla badania wpływu inicjalizacji wag na zbieżność

Inicjalizacja	Liczba epok	F1-Score	Precision	Recall	Accuracy	Final Loss
zeros	411	0.862	0.833	0.893	0.869	0.328
random	411	0.862	0.833	0.893	0.869	0.328
ones	353	0.862	0.833	0.893	0.869	0.329
uniform	412	0.862	0.833	0.893	0.869	0.328
extreme	1000	0.842	0.828	0.857	0.852	3.087

4 z 5 metod inicjalizacji (zeros, random, uniform, ones) osiągnęły dokładnie te same metryki oraz wartość końcową.

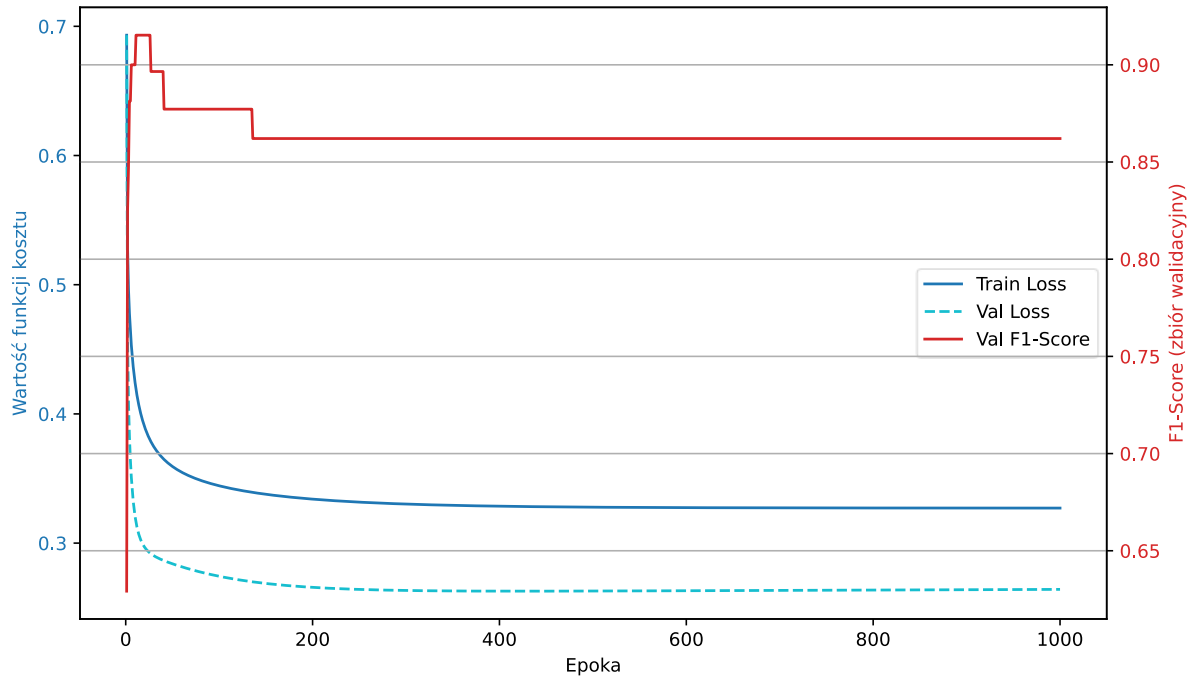
Inicjalizacje zeros, random oraz uniform startują z bardzo bliskich wartości funkcji kosztu ponieważ ich wagi oscylują wokół 0 – właściwie od początku ich krzywe są nierozróżnialne.

Inicjalizacja ones startuje z wyraźnie wyższego błędu, jednak najszybciej osiąga zbieżność. Większy początkowy błąd predykcji wygenerował na samym początku znacznie większe gradienty, co pozwoliło modelowi wykonać większe skoki w pierwszych krokach.

Linia inicjalizacji extreme leży o rząd wielkości wyżej niż pozostałe i ma bardzo powolny spadek. Dążenie do zbieżności osiągnęło limit epok ustawiony na 1000, co oznacza, że przy tych ustawieniach model nadal nie osiągnął zbieżności. Następuje wtedy zjawisko zanikającego gradientu. Funkcja straty ma wtedy wartość 3.087, czyli prawie 10 razy większą od pozostałych.

Teraz na dobranych optymalnych parametrach można sprawdzić dynamikę optymalizacji modelu w czasie za pomocą krzywej uczenia. Te parametry to:

1. learning rate = 2.0
2. weights = zeros



Wykres 4. Krzywa uczenia

Krzywa Val Loss równomiernie maleje razem z krzywą Train Loss, ostatecznie utrzymując się na niższym poziomie. Obie krzywe nie rozbiegają się, co sugeruje brak zjawiska przeuczenia.

Po 200 epoce obie krzywe utrzymują się na praktycznie tym samym poziomie do końca ewaluacji. Dalszy trening przynosi mikro spadki funkcji kosztu, a więc zastosowanie mechanizmu early stopping w okolicach 200-300 epoki oszczędzi czas i zasoby obliczeniowe bez utraty jakości klasyfikatora.

W ciągu pierwszych kilkunastu epok następuje gwałtowny spadek zarówno błędu treningowego, jak i walidacyjnego. Jednocześnie znacząco wzrasta metryka F1. Jej wartość zatrzymuje się na 0.862 i utrzymuje się tak do końca ewaluacji. Wartości metryk widoczne są w tabeli poniżej.

Tabela 3. Metryki krzywej uczenia

Liczba epok	F1-Score	Precision	Recall	Accuracy	Final Train Loss	Final Val Loss
1000	0.862	0.833	0.893	0.869	0.327	0.264

Mimo wypukłości funkcji kosztu, klasyfikator liniowy nie zawsze zbiega w praktyce do globalnego minimum, jeśli zostanie źle sparametryzowany.

Zbyt duży współczynnik uczenia ($\text{lr} \geq 10.0$) kompletnie uniemożliwia osiągnięcie zbieżności (powoduje ciągłe przeskakiwanie nad doliną minimum i niegasnące oscylacje).

Zbyt mały współczynnik uczenia ($\text{lr} \leq 0.01$) oraz skrajna inicjalizacja wag (extreme) nie blokują zbieżności całkowicie, ale drastycznie przedłużają proces uczenia (przez mikroskopijne kroki lub wejście w strefę nasycenia sigmoidy i zanikanie gradientu).